FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVOD ZA TELEKOMUNIKACIJE

HEURISTIČKE METODE OPTIMIZACIJA

Parkiranje vozila u spremištu javnog prijevoznika

Tomislav Božurić

Marin Vernier

Siječanj, 2019

Sadržaj

1 Opis problema

U svrhu ovog projekta rješavan je problem parkiranja vozila u spremištima kompanije za javni prijevoz. Svako od vozila se smješta na prometne trake i pritom moramo imati na umu vrijeme polaska vozila iz spremišta, kako bi svako vozilo na vrijeme moglo izaći iz spremišta. Sam problem definira određena ograničenja koja je bilo potrebno zadovoljiti:

- Vozilo se parkira na točno jednu traku.
- Na svaku traku se parkiraju vozila isključivo jedne serije.
- Svako vozilo se može parkirati isključivo na neku od traka koja pruža potrebnu infrastrukturu.
- Suma duljina vozila na traci ne smije premašiti kapacitet trake.
- Vozilu se može dodijeliti samo jedna pozicija u traci.
- Pozicija u redu u traci može biti dodijeljena samo jednom vozilu.
- Polazak bilo kojeg vozila u traci mora biti prije polaska vozila koje slijedi u traci.
- Polazak svih vozila u blokirajućoj traci mora biti prije prvog vozila u blokiranoj traci.

  Sam problem ima dva globalna cilja, prvi globalni cilj jest **minimizirati** broj različitih serija vozila u susjednim trakama, broj korištenih traka i neiskorišten prostor na korištenim trakama. Taj globalni cilj ignorira vremensku komponentu problema te ga opisujemo kao:

  $$\max p_1 f_1 + p_2 f_2 + p_3 f_3.$$

  Drugi globalni cilj jest **maksimizirati** broj vozila s istim tipom rasporeda unutar trake, broj vozila s istim tipom rasporeda u susjednim trakama, te maksimizirati dobru praksu glede vremenskog razmaka između dva izlaska vozila iz spremišta (idealno svaki izlazak odvojen između $[15, 20]$ minuta, najmanje je prihvatljivo da su izlasci razmaknuti manje od 10 minuta). Ovaj maksimizacijski problem možemo opisati sljedećom funkcijom:

  $$\max r_1 g_1 + r_2 g_2 + r_3 g_3$$

Cilj	*Vrijednost*	*Težinski faktor*
f_1	broj parova susjednih korištenih traka koje se razlikuju u parkiranoj seriji vozila	$\frac{1}{p_1}$ = broj korištenih traka -1
f_2	broj korištenih traka	$\frac{1}{p_2}$ = ukupni broj traka
f_3	suma neiskorištenog kapaciteta na korištenim trakama	$\frac{1}{p_3}$ = ukupni kapacitet svih traka - ukupna duljina svih vozila
g_1	broj parova susjednih vozila u traci s istim tipom rasporeda	$\frac{1}{r_1}$ = ukupni broj vozila u svim trakama - broj korištenih traka
g_2	broj susjednih korištenih traka za koje vrijedi da zadnje vozilo u traci ima raspored istog tipa kao prvo vozilo u sljedećoj traci	$\frac{1}{r_2}$ = broj korištenih traka -1
g_3	suma nagrada i penala za vremenski razmak između polazaka, za sva susjedna vozila, u svim trakama $$n = \begin{cases} 15, & 10 \leq vr \leq 20 \\ 10, & vr > 20 \\ 4 \cdot (10 - vr), & vr < 10 \end{cases} \quad (1)$$	$\frac{1}{r_3}$ = 15 $\cdot$ broj evaluiranih parova (susjeda iz traka)

Tablica 1: Opis komponenti funkcija

2 Opis primijenjenog algoritma

U svrhu rješavanja ovog projekta korištena su tri algoritma. Pohlepni algoritam, eliminacijski genetski algoritam s turnirskom selekcijom, te taboo pretraživanje u svrhu lokalnog pretraživanje nakon pronađenog rješenja koje zadovoljava gore navedena ograničenja. Na početku pomoću pohlepnog algoritma opisanog u idućem odjeljku pokušavamo razmjestiti što je više moguće vozila u trake, zatim na temelju tako dobivenog rješenja pomoću genetskog algoritma gradimo populaciju jedinki jednostavnim permutacijama, te nakon što genetskim algoritmom nađemo rješenje koje zadovoljava sva ograničenja,genetski algoritam počinje koristiti funkciju evaluacije koja dodatno optimira i dobrotu rješenja, te na kraju taboo pretraživanjem lokalno pretražujemo za još bolja rješenja. Korišten je genetski eliminacijski algoritam, kao prikaz rješenja koristi se vektor permutacija cijelih nenegativnih brojeva koji označavaju parkirnu traku na koje je pojedino vozilo parkirano. Primjerice moramo li parkirati 50 vozila u spremište javnog prijevoznika, taj vektor ima 50 elemenata i svaki element označava na kojoj traci je parkirano vozilo koje je označeno indeksom u vektoru. Kao selekcija koristi se jednostavna 3-turnirska selekcija gdje se najgora jedinka eliminira iz populacije, a preostale dvije se križaju te se naposljetku dijete mutira i dodaje u populaciju. Odabrana je 3-turnirska selekcija jer se pokazala da se dobro ponaša tijekom postupka traženja rješenja i omjer preživljavanja dobrih i loših jedinki je zadovoljavajuć. Kao metode križanja implementirane su: križanje s jednom točkom prekida, križanje s više točaka prekida, te višestruko križanje kojem preko parametra predamo željeni broj elemenata, i na temelju tog broja nasumično generiramo indekse i prilikom kreiranja nove jedinke na tim indeksima uzimamo vrijednosti od drugog roditelja, dok na preostalim indeksima elemente prvog roditelja. Za mutaciju se koristi jednostavna mutacija gdje s vjerojatnošću mutacije jedinke p_m biramo nasumično element jedinke, i mijenjamo ga nekim drugom elementom, odnosno nekom drugom parkirnom trakom. Dodatno, implementirana je i metoda uniformne mutacije, gdje iteriramo po svim elementima jedinke i s određenom vjerojatnošću uzimamo element prvog roditelja ili uzimamo element drugog roditelja. U samome radu koriste se obje vrste mutacije i svaku biramo s vjerojatnošću 0.5. Ekvivalentno, za križanje koristimo višestruko križanje s različitim brojem elemenata koje želimo naslijediti od drugog roditelja. Kad genetski algoritam naše validno rješenje, nastoji mu optimirati dobrotu rješenja, odnosno maksimizirati omjer drugog i prvog cilja, te nakon toga najbolje pronađeno rješenje predaje taboo algoritmu, koji ga koristi kao početno rješenje. Početno rješenje postavljamo kao na-

jbolje i kao trenutno rješenje. Za trenutno rješenje generiramo susjedstvo, tako da radimo permutacije svakog vozila sa svakim. Dodatno, susjedstvo čine i rasporedi gdje premještamo vozila u prazne trake. U svakoj iteraciji evaluiramo sve tako generirane susjede i tražimo najboljeg poboljšavajućeg susjeda. Kad nađemo boljeg susjeda odabiremo njega kao trenutno rješenje i pamtimo tu izmjenu u taboo listu. Algoritam staje nakon određenog broja iteracija. Detalji oko pojedinih heurističkih odnosno evolucijskih algoritama dani su u nastavku u tablicama.

Prikaz rješenja	mapa u kojoj za svaku traku imamo listu vozila
Funkcija cilja	evaluira se prema zadanim funkcijama cilja
Funkcija prikladnosti	evaluira se prema zadanim funkcijama cilja
Početno rješenje	rješenje koje je našao genetski algoritam
Trajanje tabua	8 iteracija
Generiranje susjedstva	sve permutacije vozila(uz popunjavanje praznih traka)
Kriterij zaustavljanja	50 iteracija

Tablica 2: Taboo pretraživanje

Prikaz rješenja	vektor permutacija parkirnih traka
Funkcija cilja na početku Nakon pronalaska validnog rješenja	suma svih pogrešaka koje dijele rješenje od validnog kao do tada + (maks. - min. problem)
Funkcija prikladnosti na početku Nakon pronalaska validnog rješenja	suma svih pogrešaka koje dijele rješenje od validnog kao do tada + (maks. - min. problem)
Početno rješenje	pohlepni algoritam i permutacije
Selekcija	3-turnirska selekcija
Križanje	uzimanje n elemenata druge jedinke
Mutacija	uniformna mutacija i zamjena parkirne trake vozilu
Vjerojatnost mutacije	$p_m = 0.03$
Veličina populacije	10
Kriterij zaustavljanja	vremensko ograničenje

Tablica 3: Genetski algoritam

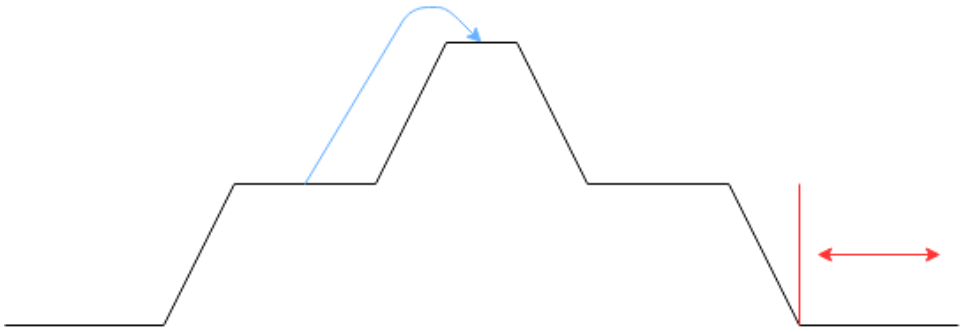

Slika. 1: Optimizacijska funkcija pronalaska rješenja koje ne krši zadana ograničenja

Najveći problem genetskom algoritmu predstavlja pronalaženje početnog rješenja koje zadovoljava sva ograničenja. Problem su ravne plohe u funkciji optimizacije koje predstavljaju broj zadovoljenih ograničenja (primjer jedne plohe crvenom bojom na grafu), i takve ravne plohe predstavljaju težak zadatak izvlačenja iz lokalnog optimuma te je zbog toga samom genetskom algoritmu potreban nešto veći broj iteracija za pronalazak početnog validnog rješenja, no kada pronađe početno validno rješenje (plavom bojom na grafu) i kada funkciji evaluacije dodajemo dobrotu pojedinog rješenja, algoritam efikasno pronalazi sve bolje i bolje jedinke, odnosno sve bolja i bolja rješenja.

3 Pseudokod

Pseudokod pohlepnog algoritma dan je u nastavku:

1. Grupiraj vozila po seriji kojoj pripadaju.
2. Za svaku seriju vozila izračunaj prosječan broj traka na koje se automobili iz te serije mogu parkirati.
3. Sortiraj rastuće serije vozila po prethodno izračunatoj mjeri.
4. Za svaku seriju iz prethodno sortirane liste dohvati vozila iz te serije i sortiraj ih rastuće po: vremenu polaska, broju parkirnih traka na koje vozilo može parkirati, tipu rasporeda te zatim po identifikatoru.

5. Za svako tako sortirano vozilo dohvati parkirne trake na koje se vozilo može parkirati i sortiraj parkirne trake rastuće po broju blokirajućih traka, pa po slobodnom prostoru na pojedinoj parkirnoj traci.

6. Za tako sortiranu listu parkirnih traka na svaku od njih pokušaj parkirati vozilo ako parkiran traka nije puna i ako se na njoj ne nalaze vozila neke druge serije.

Pseudokod genetskog eliminacijskog algoritma i taboo algoritma je klasični pristup, pa ga ovim putem ne navodim.

4 Rezultati

Iz rezultata prikazanih u nastavku možemo vidjeti kako algoritam uspješno pronalazi rješenja te parkira vozila u garažu bez kršenja ograničenja. Zbog same probabilističke prirode genetskih algoritama, vrijeme pronalaska rješenja varira u razumljivim intervalima. Rad genetskog algoritma isproban je na mnogo parametara se pokazalo da najbolja rješenja pronalazi za malu vjerojatnost mutacije (otprilike $1 - 3\%$). Također se pokazalo da za veće veličine populacije nismo dobili na kvaliteti rješenja, pa samim time zbog većeg broj operacija koje je potrebno izvesti kod veće populacije, korištena je manja populacija koja je davala rješenja jednake ili bolje kvalitete u kraćem vremenu. Bilo je potrebno dosta pripaziti na operatore križanja i mutacije zbog vrlo ograničenog problema, pa samim time je razumljivo da vjerojatnost mutacije se očekuje da bude malena (kao što je i uobičajeno), a da operatorom križanja ne izgubimo dobar genetski materijal od roditelja ili u drugoj krajnosti da nasumično pretražujemo. Također, zbog zadanih ograničenja genetskom algoritmu treba nešto više iteracija da evaluira k dobrim rješenjima, pa je bilo potrebno u svakom koraku pamtiti što je više prethodno izračunatih operacija kako ne bi bespotrebno trošili procesorsko vrijeme. Eliminacijski genetski algoritam jest nakon 1 minute izmijenio 50 000 generacija, dok je za 5 min napravio 240 000 generacija. Za prvu instancu za "beskonačno" prvu instancu smo najduže izvodili i izmijenili 9 000 000 generacija, drugu instancu 4 000 000 generacija te za treću instancu 5 900 000 generacija. Genetski algoritam nije evoluirao zadane funkcije cilja(**??** i **??**) dok nije pronašao inicijalno rješenje koje zadovoljava sva postavljena ograničenja.

Broj minuta	nakon 1 minute	nakon 5 minuta	beskonačno
f_1	0.25	0.25	0.25
f_2	0.86206895	0.86206895	0.86206895
f_3	0.3174716	0.30610797	0.30042616
g_1	0.5833334	0.625	0.75
g_2	0.7083334	0.7916667	0.9166667
g_3	0.8	0.78933334	0.8933333
$cilj_1$	1.4295405	1.4181769	1.412495
$cilj_2$	2.0916667	2.206	2.56
$omjer$	1.463174356	1.555518215	1.812395796

Tablica 4: Rezultati prve instance

Broj minuta	nakon 1 minute	nakon 5 minuta	beskonačno
f_1	0.3846154	0.3846154	0.34615386
f_2	0.9310345	0.9310345	0.9310345
f_3	0.64624506	0.6284585	0.6185771
g_1	0.61538464	0.7692308	0.8846154
g_2	0.5769231	0.7692308	0.7692308
g_3	0.7820513	0.82051283	0.8717949
$cilj_1$	1.961895	1.9441084	1.8957654
$cilj_2$	1.974359	2.3589745	2.5256412
$omjer$	1.006353041	1.213396588	1.332254086

Tablica 5: Rezultati druge instance

Broj minuta	nakon 1 minute	nakon 5 minuta	beskonačno
f_1	0.60714287	0.5185185	0.4814815
f_2	1.0	0.9655172	0.9655172
f_3	0.9762846	0.80138344	0.82114625
g_1	0.625	0.84	0.79999995
g_2	0.46428573	0.7037037	0.8518519
g_3	0.4638889	0.85333335	0.8666667
$cilj_1$	2.5834274	2.2854192	2.268145
$cilj_2$	1.5531746	2.397037	2.5185184
$omjer$	0.6012069857	1.048839093	1.110386858

Tablica 6: Rezultati treće instance

5 Zaključak

Projekt se pokazao kao dosta izazovan i bilo je zanimljivo vidjeti kako u praksi izgleda rješavanje nekog tako ograničavajućeg problema. S obzirom na to da genetski algoritam se može vrlo različito ponašati za male promjene u parametrima, kao prijedlog jednog od daljnjih poboljšanja bi bilo provođenje statistike za različite parametre genetskog algoritma i uzimanjem najbolje prosječne vrijednosti odrediti optimalne parametre inicijalno implementiranog genetskog algoritma. U svrhu dodatnog poboljšanja vremena potrebnog za pronalazak rješenja mogli bismo u više dretvi pokrenuti više instanci odnosno napraviti *thread-pool* te pratiti u određenim vremenskim razmacima napredovanje pojedine instance i onu najbolju ostaviti aktivnom.